Kviz 3

Statistika 2024/25

Jan Panjan

2024-12-12

Table of contents

Uporabljeni paketi	1
Branje podatkov	1
Navodila	2
Naloga 1	2
Naloga 2	3
Naloga 3	7
Naloga 4	0

Uporabljeni paketi

```
library(tidyverse)
library(ggplot2)
```

Branje podatkov

```
data <- read.delim("data.txt")
x <- 8 # prezadnja števka
z <- 2 # zadnja števka
data[unique(c(seq(x, nrow(data), 10), seq(z, nrow(data), 10))), ] %>%
    as.data.frame() -> my.data
nrow(my.data)
```

[1] 105

Preimenoval bom stolpce za lažje delo.

```
names(my.data) <- names(my.data) |>
  gsub(pattern = "\\.+", replacement = "_") |>
  gsub(pattern = "_$", replacement = "")

names(my.data)
```

```
"Age"
 [1] "Timestamp"
 [3] "Sex"
                                 "Height"
 [5] "Weight"
                                 "Shoe_size"
 [7] "Eye_Color"
                                 "Smoking"
 [9] "Smoking_How_many_per_day" "Videogames"
[11] "TV_hours_per_week"
                                 "Internet_hours_per_week"
[13] "Books_how_many_per_year"
                                 "Sport_hours_per_week"
[15] "Pet"
                                 "Faculty"
[17] "Friends_on_Facebook"
                                 "Sleep_hours_per_night"
[19] "PetBird"
                                 "PetCat"
[21] "PetDog"
                                 "PetFish"
[23] "Petno"
                                 "PetOther"
[25] "PetRodent"
```

Navodila

Vaša naloga bo narediti več statističnih analiz. Vsaka statistična analiza naj vključuje: - eksplicitno zapisani ničelno in alternativno hipotezo, - utemeljitev uporabe izbranega statističnega testa, - izračun z R, - statistični sklep - in vsebinski sklep.

Če ni določeno drugače, uporabite $\alpha = 0.05$.

Naloga 1

 $Pri \alpha = 0.01$ preverite ali se številka čevlja razlikuje pri študentih in študentkah.

```
df <- select(my.data, Sex, Shoe_size) |>
  filter(Sex %in% c("male", "female"))

df |> summarise(
```

```
n = n(),
povprecje = mean(Shoe_size),
"std. odklon" = sd(Shoe_size),
.by = Sex
)
Sex n povprecje std. odklon
```

```
sz_M <- my.data[my.data$Sex == "male", "Shoe_size"]
sz_F <- my.data[my.data$Sex == "female", "Shoe_size"]
t.test(sz_M, sz_F, sig.level = 0.01, alternative = "two.sided")</pre>
```

```
Welch Two Sample t-test

data: sz_M and sz_F

t = 12.301, df = 41.988, p-value = 1.649e-15

alternative hypothesis: true difference in means is not equal to 0

95 percent confidence interval:

4.121551 5.739391

sample estimates:

mean of x mean of y

43.61290 38.68243
```

1.383796

2.044137

Visoka p vrednost nakazuje na to, da odstopanja niso statistično značilna - H_0 obdrđimo. Velikost čevlja se med študenti in študentkami razlikuje.

Naloga 2

1 female 74 38.68243


male 31 43.61290

Predstavite podatke za številko čevlja in težo z ustreznim grafom. Preverite ali je številka čevlja linearno odvisna od teže v populaciji študentov. Interpretirajte rezultate. Komentirajte ali je predstavljen problem smiselno zastavljen.

- H_0 : številka čevlja in teža sta linearno odvisni spremenljivki
- H_1 : številka čevlja in teža nista linearno odvisni spremenljivki

```
ggplot(df, aes(x = Shoe_size)) +
  geom_histogram(binwidth = 1) +
  facet_wrap(~ Sex, ncol = 2) +
  labs(
    x = "Velikost čevlja",
    y = "Frekvenca",
    title = "Porazdelitev velikosti čevlja glede na spol"
)
```


Porazdelitev velikosti cevlja glede na spol



```
df2 <- select(my.data, Sex, Weight) |>
  filter(Sex %in% c("male", "female"))

ggplot(df2, aes(x = Weight)) +
  geom_histogram(binwidth = 5) +
  facet_wrap(~ Sex, ncol = 2) +
  labs(
    x = "Teža",
    y = "Frekvenca",
    title = "Porazdelitev teže glede na spol"
)
```

Porazdelitev teže glede na spol



```
w_M <- filter(my.data, Sex == "male") |>
    select(Weight) |>
    unlist() |>
    setNames(NULL)

cor.test(
    x = sz_M,
    y = w_M,
    method = "pearson",
    alternative = "two.sided"
)
```


Pearson's product-moment correlation

Korelacija ≈ 0.695 je nadpovprečna, zato lahko trdim, da sta teža in velikost noge linearno korelirani. Podobno je razvidno iz spodnjega grafa. Hipotezo H_0 zavržemo v prid alternativne domneve H_1 .

```
ggplot(
  data.frame(
    "ShoeSize" = sz_M,
    "Weight" = w_M
),
  aes(x = ShoeSize, y = Weight)
) +
  geom_point() +
  geom_smooth() +
  labs(
    title = "Odvisnost med velikostjo noge in težo",
    x = "Velikost noge",
    y = "Teža"
)
```

 $\ensuremath{\text{`geom_smooth()`}}\ using method = 'loess' and formula = 'y ~ x'$

Odvisnost med velikostjo noge in težo



Naloga 3

Preverite ali sta Teža in število ur športa na teden monotono povezani slučajni spremenljivki v populaciji.

- H_0 : število ur športa na teden in teža sta monotono povezani spremenljivki
- H_1 : število ur športa na teden in teža nista monotono povezani spremenljivki

```
df3 <- select(my.data, Weight, Sport_hours_per_week, Sex)</pre>
```

```
cor.test(
  x = {
    filter(df3, Sex == "male") |> select(Sport_hours_per_week) |> unlist()
  },
  y = {
    filter(df3, Sex == "male") |> select(Weight) |> unlist()
  },
  method = "spearman",
  alternative = "two.sided"
)
```

Warning in cor.test.default(x = {: Cannot compute exact p-value with ties

Spearman's rank correlation rho

```
data: { unlist(select(filter(df3, Sex == "male"), Sport_hours_per_week)) } and {
S = 3199, p-value = 0.05001
alternative hypothesis: true rho is not equal to 0
sample estimates:
    rho
0.3550325
```

un


Vrednost 0.05 ne implicira monotone korelacije med težo in število ur športa na teden v populaciji študentov. To je razvidno tudi iz razpršenosti točk na grafu.

 H_0 zavržemo v prid alternativne domneve H_1 , saj so odstopanja statistično značilna.

```
ggplot(
  data.frame(
    "w" = { filter(df3, Sex == "male") |> select(Weight) |> unlist() },
    "spw" = { filter(df3, Sex == "male") |> select(Sport_hours_per_week) |> unlist() }
),
  aes(x = spw, y = w)
) +
  geom_point() +
  geom_smooth() +
  labs(
    title = "Povezanost med težo noge in števila ur športa na teden v populaciji",
    x = "Število ur športa na teden",
    y = "Teža"
)
```

`geom_smooth()` using method = 'loess' and formula = 'y ~ x'

Povezanost med težo noge in števila ur športa na teden v popi



```
cor.test(
  x = {
    filter(df3, Sex == "female") |> select(Sport_hours_per_week) |> unlist()
  },
```

```
y = {
   filter(df3, Sex == "female") |> select(Weight) |> unlist()
},
method = "spearman",
alternative = "two.sided"
)
```

Warning in cor.test.default(x = {: Cannot compute exact p-value with ties


Spearman's rank correlation rho


Vrednost 0.64 implicira, da obstaja visoka monotona korelacija med težo in število ur športa na teden v populaciji študentk. Točke na grafu so manj razpršene, kot pri študentih.

 H_0 obdržimo, saj odstopanja niso statistično značilna.

```
ggplot(
  data.frame(
    "w" = { filter(df3, Sex == "female") |> select(Weight) |> unlist() },
    "spw" = { filter(df3, Sex == "female") |> select(Sport_hours_per_week) |> unlist() }
),
  aes(x = spw, y = w)
) +
  geom_point() +
  geom_smooth() +
  labs(
    title = "Povezanost med težo noge in števila ur športa na teden v populaciji",
    x = "Velikost noge",
    y = "Teža"
)
```

^{&#}x27;geom_smooth()' using method = 'loess' and formula = 'y ~ x'





Naloga 4

Preverite ali je zastopanost domačih ljubljenčkov v populaciji študentov različna od: pes 41%, mačka 33%, riba 10%, drugo 16%.

```
studenti <- filter(my.data, Sex == "male") |> select(Pet)
head(studenti)
```

```
Pet
1 Fish, Bird
2 Cat
3 Cat
4 no
5 no
6 no
```

```
pets <- studenti |>
  separate_wider_delim(
  delim = ", ",
  cols = Pet,
```

```
names = c("a", "b", "c"),
    too_few = "align_start"
  ) |>
  map_df(str_to_lower)
head(pets)
# A tibble: 6 x 3
        b
  <chr> <chr> <chr>
1 fish bird <NA>
2 cat
        <NA> <NA>
3 cat
        <NA> <NA>
4 no
        <NA> <NA>
        <NA> <NA>
5 no
        <NA> <NA>
6 no
# funkcija vrne število vrstic s `pet`
pet_count <- \(pet) {</pre>
  if (!is.character(pet)) {
    message("pet must be a character vector.")
    return(0)
  }
  pets |>
    unlist() |>
    grep(pattern = pet) |>
    length()
pet_types <- c("dog", "cat", "fish", "other")</pre>
pets_freq <- sapply(pet_types, pet_count)</pre>
pets_freq
        cat fish other
  dog
    9
        8
              6 5
chisq.test(x = pets_freq, p = c(0.41, 0.33, 0.10, 0.16), rescale.p = T)
```

Warning in chisq.test(x = pets_freq, p = c(0.41, 0.33, 0.1, 0.16), rescale.p = T): Chi-squared approximation may be incorrect

Chi-squared test for given probabilities

data: pets_freq
X-squared = 4.4197, df = 3, p-value = 0.2196